

UNIVERSITÀ DEGLI STUDI DI SALERNO



Previsione dell'abbandono universitario con Machine Learning

Classificazione binaria precoce di studenti a rischio

Dataset UCI Predict Students Dropout and Academic Success

Corso	Machine Learning
Corso di laurea	Informatica, 3° anno
Autore	Francesco Di Giovanni
Anno accademico	2025/2026

Report di progetto

Sintesi esecutiva

Il progetto affronta un task di classificazione supervisionata binaria volto a prevedere, a partire dalle informazioni disponibili entro il primo semestre, se uno studente finirà nella classe Dropout oppure Graduate. Dopo la rimozione della classe Enrolled e di tutte le feature del secondo semestre, il dataset finale di lavoro contiene 3.630 studenti e 31 colonne. Le analisi esplorative mostrano che le performance accademiche del primo semestre sono i predittori più informativi dell'esito finale, mentre diverse variabili codificate numericamente devono essere trattate come categoriche. Il confronto tra Gaussian Naive Bayes, Decision Tree e Random Forest evidenzia quest'ultima come modello migliore nel complesso, con accuracy 88,84%, precision sulla classe Dropout 91,77% e F1-score 84,63%.

Struttura del report

- 1. Scenario, problema e task analizzato
- 2. Dataset utilizzato e caratteristiche principali
- 3. Issue analizzate, soluzioni proposte e scelte di progettazione
- 4. Analisi delle prestazioni con dati numerici e grafici
- 5. Considerazioni finali e possibili sviluppi futuri



1. Scenario, problema e task analizzato

Il progetto si colloca nel dominio educativo e, più precisamente, nel contesto universitario. L'obiettivo è costruire un sistema di allerta precoce in grado di supportare la segreteria didattica e gli organi di orientamento nell'individuazione degli studenti a rischio di abbandono. Il problema presenta un valore applicativo concreto: intercettare tempestivamente segnali di fragilità consente di immaginare interventi mirati, come tutorato, supporto organizzativo o azioni di monitoraggio.

1.1 Scelta del dominio

Il dominio educativo è particolarmente adatto al Machine Learning perché combina dati anagrafici, socio-economici, accademici e di contesto macroeconomico. In questo scenario, la previsione dell'esito universitario non ha solo una valenza descrittiva, ma può tradursi in un supporto decisionale concreto per l'Ateneo.

1.2 Definizione del task

Il dataset originale presenta un target multiclass con tre possibili valori: Dropout, Graduate ed Enrolled. Ai fini del progetto, la classe Enrolled è stata rimossa perché descrive una condizione transitoria e non un esito finale. Il task è stato quindi riformulato come classificazione supervisionata binaria, con:

- classe positiva (1): Dropout;
- classe negativa (0): Graduate.

La formulazione corretta del problema è la seguente: usando le informazioni disponibili entro il primo semestre, il modello cerca di prevedere se lo studente finirà nella classe Dropout oppure Graduate. Non si sta quindi predicendo l'abbandono entro il primo anno, ma l'esito finale osservato nel dataset attraverso una previsione precoce.

1.3 Domande di ricerca

- Le performance accademiche del primo semestre sono predittive dell'esito finale?
- Le informazioni anagrafiche, economiche e di iscrizione aiutano a distinguere Dropout e Graduate?
- Quale modello classico tra Gaussian Naive Bayes, Decision Tree e Random Forest risulta più efficace?



2. Il dataset utilizzato e le sue caratteristiche

Il dataset adottato è Predict Students Dropout and Academic Success, pubblicato nella UCI Machine Learning Repository. Ogni riga rappresenta uno studente e ogni colonna descrive una caratteristica rilevante del suo profilo personale, accademico o di contesto.

2.1 Struttura del dataset

La versione originale contiene 4.424 righe e 37 colonne. Dopo la rimozione delle istanze con Target = Enrolled e l'eliminazione di tutte le feature del secondo semestre, il dataset finale di lavoro contiene 3.630 studenti e 31 colonne.

Versione	Righe	Colonne	Note
Originale	4.424	37	Target multiclass
Finale	3.630	31	Task binario e rimozione del 2° semestre

2.2 Categorie di feature

Le variabili considerate nel progetto possono essere raggruppate in quattro famiglie principali:

- dati anagrafici e socio-economici;
- dati di iscrizione e background accademico;
- performance accademica del primo semestre;
- dati macro-economici riferiti al momento dell'iscrizione.

Le feature del secondo semestre sono state escluse integralmente per evitare fenomeni di data leakage, poiché forniscono informazioni troppo vicine o successive all'esito finale.

2.3 Controlli preliminari

Il dataset è stato controllato dal punto di vista strutturale prima di procedere con le analisi esplorative. I risultati mostrano:

- 24 colonne di tipo int64, 6 colonne float64 e 1 colonna object (Target);
- assenza di missing values;
- assenza di righe duplicate.

Il dataset risulta quindi già pulito sotto il profilo strutturale; le principali criticità del progetto sono di natura metodologica e interpretativa, non di mera pulizia dei dati.

2.4 Distribuzione del target

Dopo la rimozione della classe Enrolled, il target finale è distribuito in 2209 casi Graduate (60.85%) e 1421 casi Dropout (39.15%). Lo sbilanciamento è presente ma moderato, per cui l'accuracy non può essere considerata una metrica sufficiente da sola.






Figura 1 - Distribuzione della variabile target nel dataset finale.

2.5 Distinzione tra feature numeriche e categoriche

Un passaggio centrale dell'analisi è stato distinguere tra feature realmente numeriche e feature categoriche codificate con numeri. Il tipo `int64`, infatti, non garantisce da solo una natura quantitativa. Variabili come `Course`, `Marital status`, `Gender`, `Debtor` o `Scholarship holder` sono codici e non quantità; trattarle come numeriche avrebbe introdotto relazioni ordinali artificiali.

2.6 Analisi esplorativa dei dati

Sono stati prodotti grafici a barre, boxplot, scatterplot e heatmap per individuare pattern, asimmetrie, outlier e relazioni tra le variabili. In particolare:

- `Curricular units 1st sem (approved)` e `Curricular units 1st sem (grade)` mostrano una forte capacità discriminante;
- `Admission grade` e `Previous qualification (grade)` risultano positivamente correlati;
- molti outlier appaiono plausibili e coerenti con la natura delle variabili;
- diverse feature del primo semestre presentano correlazioni elevate, suggerendo una possibile ridondanza.






Figura 2 - Distribuzione della variabile target per alcune feature selezionate.






Figura 3 - Boxplot rispetto al target per alcune feature selezionate.






Figura 4 - Heatmap delle feature numeriche reali.



Scatterplot: Admission grade vs Curricular units 1st sem (grade)




Figura 5 – Scatterplot Curricular units 1st sem(grade) / Admission grade






Figura 6 – Scatterplot Admission grade / Age at enrollment






Figura 7 – Scatterplot Admission grade / Previous qualification (grade)



2.7 Statistiche descrittive selezionate

Variabile	Media	Mediana	Min	Max
Age at enrollment	23,46	20,00	17	70
Previous qualification (grade)	132,92	133,10	95	190
Admission grade	127,29	126,50	95	190
Curricular units 1st sem (evaluations)	8,07	8,00	0	45
Curricular units 1st sem (approved)	4,79	5,00	0	26
Curricular units 1st sem (grade)	10,53	12,34	0	18,88



3. Le issue analizzate, le soluzioni proposte e le scelte di progettazione

Il cuore del progetto non è consistito nell'aggiungere trasformazioni artificiali al dataset, ma nel prendere decisioni corrette sulle principali issue metodologiche emerse dall'analisi.

3.1 Riformulazione del target

Il target originale multiclass è stato trasformato in un task binario rimuovendo tutte le istanze con Target = Enrolled. Questa scelta ha permesso di concentrare l'analisi su due esiti finali mutuamente esclusivi: Dropout e Graduate.

3.2 Rischio di data leakage

Tutte le colonne del secondo semestre sono state eliminate preventivamente. La motivazione è forte: usare variabili troppo vicine all'esito finale avrebbe reso la previsione poco realistica, perché il modello avrebbe avuto accesso a informazioni che non sarebbero disponibili al momento di una reale decisione operativa.

3.3 Missing values e duplicati

Le verifiche hanno mostrato l'assenza di missing values e duplicati. Di conseguenza, non è stata applicata alcuna imputazione né alcuna rimozione addizionale.

3.4 Outlier

I boxplot hanno evidenziato la presenza di valori estremi in più variabili; tuttavia, molti di essi risultano plausibili, rari ma realistici, oppure dipendono da distribuzioni discrete e zero-inflated. Per questo motivo è stata esclusa una rimozione automatica degli outlier.

3.5 Feature categoriche codificate numericamente

Le feature numeriche per forma ma categoriche per semantica sono state identificate esplicitamente e trattate come categorie. Questa scelta evita interpretazioni ordinali arbitrarie, ad esempio tra codici di corso o stato civile.

3.6 One-Hot Encoding

Per tutte le feature categoriche è stata adottata la codifica One-Hot. Ciò consente ai modelli di lavorare con indicatori binari senza imporre distanze o ordini inesistenti tra i valori originari.

3.7 Scaling selettivo

Lo scaling non è stato applicato indiscriminatamente a tutti i modelli. Gli algoritmi tree-based operano tramite soglie e split e risultano sostanzialmente insensibili alla scala numerica. Per Gaussian Naive Bayes, invece, è stata adottata una standardizzazione delle feature numeriche all'interno della pipeline.

3.8 Feature ridondanti

La heatmap ha evidenziato correlazioni elevate tra alcune variabili del primo semestre. Per verificare la ridondanza è stato svolto un piccolo studio di ablazione, da cui è emerso che



Curricular units 1st sem (credited) è la feature più sacrificabile; tuttavia, il modello completo continua a essere il migliore, per cui nel progetto principale le feature sono state mantenute.

3.9 Sbilanciamento delle classi

Lo sbilanciamento tra Graduate e Dropout è moderato. Si è scelto di gestirlo principalmente a livello di metriche, valutando con attenzione precision, recall, F1-score e confusion matrix sulla classe Dropout. È stato testato anche un approccio algorithm-level con `class_weight='balanced'` per la Random Forest, ma il risultato è stato lievemente inferiore al modello standard.

3.10 Pipeline finale di preprocessing

- caricamento del dataset e selezione delle colonne rilevanti;
- rimozione delle istanze con Target = Enrolled;
- eliminazione di tutte le feature del secondo semestre;
- distinzione tra feature numeriche reali e categoriche codificate numericamente;
- One-Hot Encoding delle feature categoriche;
- scaling selettivo delle feature numeriche solo per Gaussian Naive Bayes;
- train/test split stratificato;
- preprocessing differenziato in pipeline separate per modello.

3.11 Verifica della ridondanza e dello sbilanciamento

Le due verifiche più rilevanti del Capitolo 3 riguardano l'ablazione di feature sospette e la prova con Random Forest bilanciata.

Setup	Accuracy	Precision Dropout	Recall Dropout	F1 Dropout
Completo	0,8884	0,9177	0,7852	0,8463
Senza credited	0,8829	0,9095	0,7782	0,8387
Senza enrolled	0,8815	0,8960	0,7887	0,8390

Tabella 1 - Mini studio di ablazione sulle feature ridondanti.

Nel test con `class_weight='balanced'` la Random Forest ha ottenuto Accuracy 0,8829, Balanced Accuracy 0,8629, Precision Dropout 0,9163, Recall Dropout 0,7711 e F1 Dropout 0,8375. Il lieve peggioramento conferma che, nel progetto principale, non conviene intervenire ulteriormente sul bilanciamento del modello.



4. L'analisi delle prestazioni: dati numerici e grafici

4.1 Setup sperimentale

Il dataset finale è stato suddiviso in training set e test set secondo uno split 80/20, mantenendo la stratificazione sulla variabile target. In questo modo le proporzioni tra Graduate e Dropout restano coerenti nei due insiemi. Le trasformazioni di preprocessing sono state incorporate in pipeline separate per evitare leakage e garantire un trattamento coerente dei dati per ciascun modello.

- X: insieme delle feature esplicative;
- y: target binario Dropout vs Graduate;
- split 80% training e 20% test;
- stratify = y per preservare la distribuzione delle classi.

4.2 Modelli considerati

Sono stati confrontati tre modelli, scelti per coerenza con i materiali del corso e per rappresentare tre approcci diversi al problema.

- Gaussian Naive Bayes come baseline statistica;
- Decision Tree come modello interpretabile basato sull'impurità di Gini;
- Random Forest come ensemble di alberi con bagging e random subset di feature.

4.3 Metriche di valutazione

La valutazione non è stata basata sulla sola accuracy. Poiché la classe di maggiore interesse applicativo è Dropout, sono state considerate in modo particolare precision, recall, F1-score e confusion matrix riferite a tale classe. L'accuracy è stata mantenuta come indicatore complessivo, mentre la balanced accuracy è stata usata come supporto per tener conto dello sbilanciamento moderato.

4.4 Risultati numerici

Modello	Accuracy	Bal. Accuracy	Precision D.	Recall D.	F1 D.
GaussianNB	0,4105	0,5102	0,3963	0,9683	0,5624
Decision Tree	0,8554	0,8453	0,8255	0,7993	0,8122
Random Forest	0,8884	0,8700	0,9177	0,7852	0,8463

Tabella 2 - Confronto tra i tre modelli sul test set.






Figura 8 - Confronto sintetico delle principali metriche sul test set.

Il Gaussian Naive Bayes ottiene una recall molto elevata sulla classe Dropout, ma a costo di una precision molto bassa e di una accuracy complessiva insufficiente: il modello tende infatti a classificare come Dropout un numero eccessivo di studenti. Il Decision Tree rappresenta un netto miglioramento e fornisce risultati bilanciati, oltre a un'elevata interpretabilità. La Random Forest, infine, è il modello migliore nel complesso: pur avendo una recall leggermente inferiore rispetto al Decision Tree, raggiunge una precision sensibilmente più alta, una accuracy superiore e il miglior F1-score.

4.5 Confusion matrix e analisi degli errori




Figura 9 - Confusion matrix del modello Random Forest.

Assumendo Dropout come classe positiva, la confusion matrix della Random Forest mostra 223 veri positivi, 422 veri negativi, 20 falsi positivi e 61 falsi negativi. I due tipi di errore non hanno lo stesso peso pratico.



- Falsi positivi (20): studenti Graduate segnalati come a rischio; il costo è prevalentemente gestionale e corrisponde a un possibile intervento superfluo.
- Falsi negativi (61): studenti realmente Dropout classificati come Graduate; questo è l'errore più critico perché implica la perdita di studenti a rischio non intercettati in tempo.

L'analisi evidenzia che la Random Forest riduce in modo marcato i falsi allarmi, mantenendo comunque una buona capacità di intercettare gli studenti a rischio. Il modello è quindi adatto come strumento di supporto decisionale precoce, pur non essendo perfetto e lasciando una quota non trascurabile di casi difficili.

4.6 Scelta del modello migliore

La Random Forest è stata scelta come modello finale. La decisione non è basata soltanto sulla accuracy più alta, ma sul miglior compromesso complessivo tra precision, F1-score, robustezza e capacità di generalizzazione. Il Decision Tree presenta una recall leggermente superiore sulla classe Dropout, ma la Random Forest riduce la varianza del singolo albero e fornisce prestazioni più stabili sui dati non visti. In sintesi, la Random Forest non vince per una singola metrica, ma perché rappresenta la soluzione più solida nel complesso.



5. Considerazioni finali e sviluppi futuri

Il progetto dimostra che le informazioni disponibili entro il primo semestre sono già sufficienti per costruire un modello predittivo utile sul problema dell'abbandono universitario. La parte più informativa del dataset è legata alla performance accademica del primo semestre, mentre le variabili anagrafiche, di iscrizione e di contesto contribuiscono a completare il quadro.

Dal punto di vista metodologico, l'aspetto più rilevante non è stato aggiungere complessità inutile, ma mantenere coerenza rispetto al task: riformulazione corretta del target, prevenzione del leakage, distinzione tra feature numeriche e categoriche, uso di pipeline differenziate e valutazione attenta degli errori.

Dal confronto sperimentale emerge la Random Forest come miglior modello. Il Gaussian Naive Bayes ha svolto il ruolo di baseline statistica, evidenziando i limiti dell'ipotesi di indipendenza condizionata su un dataset con feature fortemente correlate. Il Decision Tree ha mostrato una buona qualità predittiva e un'elevata interpretabilità. La Random Forest, infine, ha fornito il miglior compromesso globale.

5.1 Sviluppi futuri

- ottimizzazione della soglia decisionale per favorire ulteriormente la recall della classe Dropout;
- analisi più approfondita delle predizioni per sottoinsiemi di studenti (slice-based evaluation);
- integrazione di nuove variabili di contesto o indicatori psicometrici, se disponibili;
- studio di strumenti di interpretabilità locale per comprendere meglio i casi di errore.

Osservazione conclusiva

Anche ricorrendo esclusivamente a modelli classici, un approccio metodologicamente corretto e coerente con i materiali del corso può produrre risultati solidi, difendibili e utili in un problema reale.

